

기존 항생제 검사 결과로 다른 항생제의 감수성 예측하기

CDLD의 소수 관측 적응과 MIMIC-eICU 평가

기존약 검사 4개 + 목표약 관측 10-50개

Dohyoung Rim | Independent Researcher

I/R	S	S	I/R	?
S	S	I/R	S	?
S	I/R	S	S	?
I/R	S	S	I/R	?
S	S	I/R	S	?
S	I/R	S	S	?

사례 × 항생제 반응

연구 질문: 기존 검사로 새 목표약의 반응을 얼마나 예측할까?

알고 있는 것

한 사례에서 관측한
기존 항생제 4개의 검사 결과

추가로 얻는 것

목표 항생제의 정답이 있는
소수 사례: support

예측할 것

목표 항생제의 결과를 가린
다른 사례: query

‘신규약’ = 모델의 사전학습에 포함되지 않은 목표 항생제

항생제 감수성 검사(AST): 배양된 균이 특정 항생제에 감수성을 보이는지 확인하는 검사

한 사례에는 네 검사 결과와 하나의 예측 목표가 있다

가상 예시 · 실제 환자 기록이 아님

기존약	관측 결과
Cefepime	감수성 S
Ciprofloxacin	비감수성 I/R
Tobramycin	감수성 S
Piperacillin/tazobactam	감수성 S



목표약: Meropenem

support 사례 → 정답을 적응에 사용
query 사례 → 정답은 평가에 사용

사례(episode)는 배양 검체·균종 등에 따라 구성한 분석 단위. 한 환자가 여러 사례를 가질 수 있음

CDLD: 관측된 관계에서 양쪽 대상의 특징을 학습한다

Cyclic Dual Latent Discovery

출발점: 두 종류 대상 사이의 반응 기록

	약물 A	약물 B	약물 C	약물 D
사례 1	S	I/R	?	S
사례 2	I/R	S	S	?
사례 3	S	?	S	I/R
사례 4	?	S	I/R	S



Dual · 두 종류의 표현


사례의 특징과 약물의 특징을
함께 추정한다

Cyclic · 번갈아 학습

한쪽 표현을 고정하고 다른 쪽을 갱신
관측된 반응에 맞추며 반복한다

추천시스템의 사용자-항목 관계에서 출발한 방법을 사례-항생제 반응에 적용

왜 CDLD인가? 새 대상의 표현을 소수 관측으로 추정할 수 있다



이번 연구의 질문: 이 적응 방식이 적은 관측에서도 예측 이득을 제공하는가?


CDLD는 사례와 약물을 각각 수치 벡터로 표현한다



목표약에 감수성일 예측 확률

latent = 반응 관계에서 학습한 수치 표현. 사례와 약물의 반응 특성을 예측에 사용하는 표현

사전학습: 두 표현을 번갈아 갱신하고 예측기를 학습한다



Finder: 1 ↔ 2를 순환

목표약·개발약은 사전학습에서 제외

적응: 기존 모델을 고정하고 새 엔티티의 latent를 찾는다



support 10 → 20 → 30 → 40 → 50

목표약 latent는 조합·seed·반복·support 크기가 같은 조건 안에서 공유

환자를 분리하고, 다른 자료에서도 같은 모델을 평가했다

MIMIC-IV 3.1 · 학습과 내부 평가



MIMIC query

992명 · 1,778 사례
28개 균종-약물 조합

eICU-CRD 2.0 외부 평가

155명 · 218 사례
MIMIC에서 적응한 모델 적용

같은 환자의 사례는 같은 분할에 유지. eICU 목표약 정답은 평가에만 사용

같은 관측을 주고, 학습 방식이 다른 방법들을 비교했다

방법	기존약 반응 사전학습	목표약 support 활용
CDLD	사례·약물 표현 + 비선형 예측기	목표약 latent 적응
MF	사례·약물 벡터의 내적 + 편향	목표약 벡터·편향 적응
L2 로지스틱 / RF / XGBoost	—	기존 AST → 목표약 직접 학습
빈도 기준선	—	support의 감수성 비율
AST 평균	—	기존약 4개 중 감수성 비율

공통: 동일 사례 · 기존약 4개 · support 정답 · query

성능에는 두 질문이 있다: 잘 구분하는가, 잘 판정하는가?

AUROC · 구분 능력

감수성 사례에 비감수성 사례보다
높은 예측 점수를 주는가?

0.5는 무작위 수준 · 1은 완전 구분

0.5 기준 · 분류 결과

점수가 0.5 이상이면 감수성으로 판정

감수성 민감도: S를 S로 찾는 비율
특이도: I/R을 I/R로 찾는 비율

정확도 = 전체 정답 비율 $F1(S)$ = 감수성 정밀도와 민감도의 조화평균

MIMIC · 전체 방법의 성능 비교

방법	AUROC	정확도	민감도(S)	F1(S)	특이도
CDLD	0.8250	0.8395	0.9296	0.8796	0.4506
MF	0.8478	0.8401	0.9379	0.8845	0.5406
L2 logistic	0.8046	0.8266	0.9374	0.8714	0.3691
RF	0.7888	0.8107	0.9325	0.8605	0.3284
XGBoost	0.7879	0.8287	0.9228	0.8707	0.4134
AST mean	0.8367	0.7641	0.9442	0.8429	0.3884
Frequency	0.5000	0.7318	0.9143	0.7734	0.0857

학습 방법 중 MF가 다섯 지표에서 최고값을 보였다

목표약 관측 50개 · 28조합 평균. 굵은 값: 학습 방법 중 최고. AST 평균은 support 미사용


eICU · 전체 방법의 성능 비교

방법	AUROC	정확도	민감도(S)	F1(S)	특이도
CDLD	0.8474	0.8725	0.9247	0.9002	0.4629
MF	0.8193	0.8363	0.8997	0.8810	0.5362
L2 logistic	0.7490	0.8307	0.8432	0.8454	0.3990
RF	0.7212	0.8201	0.8292	0.8273	0.3633
XGBoost	0.7293	0.8296	0.8387	0.8507	0.4372
AST mean	0.8601	0.8032	0.9436	0.8700	0.3327
Frequency	0.5000	0.8140	0.9143	0.8233	0.0923

학습 방법 중 CDLD는 네 지표, MF는 특이도에서 최고값을 보였다

목표약 관측 50개 · AUROC·특이도 26조합, 나머지 28조합. 굵은 값: 학습 방법 중 최고

MIMIC: support가 늘면 MF의 AUROC가 CDLD를 넘어선다




10개: CDLD > MF
20개부터: MF > CDLD

관측 증가의 이득이 다름

28조합 동일가중 평균 AUROC. 전체 방법의 성능표는 앞 절에 제시

eICU: 관측 10–50개에서 CDLD의 AUROC가 MF보다 높았다



10–50개 모두
CDLD > MF

MIMIC과 다른
상대 성능

26조합 동일가중 평균 AUROC. support는 MIMIC에서 제공

Support 0은 '목표약 latent를 갱신하지 않은' 비교 조건이다

Support 0

기존약 모델: 학습됨
사례 latent: 네 AST로 추정
목표약 latent: 초기값 유지

Support 50

같은 기존약 모델
같은 사례 latent
목표약 latent: 정답 50개로 갱신

이 비교는 목표약 support 적응이 추가한 효과를 보여준다

CDLD 적응은 정확도를 높였지만, 비감수성 검출은 낮아졌다

support 0 → 50	정확도 ↑	특이도 ↓	AUROC ↓
MIMIC	0.7774 → 0.8395	0.4975 → 0.4506	0.8280 → 0.8250
eICU	0.8114 → 0.8725	0.5672 → 0.4629	0.8567 → 0.8474

정확도 상승

MIMIC +6.21%p
eICU +6.11%p


특이도 하락

MIMIC -4.69%p
eICU -10.43%p

굵은 값: 적응 전후 중 높은 값. 감수성 민감도·F1은 두 자료 모두 상승. 판정 임계값 0.5

확률 손실은 낮아져도 AUROC가 함께 오르지 않는다

CDLD query BCE · 낮을수록 좋음



x축: 목표약 support 수. BCE는 확률 손실의 보조 지표로 제시

학습 목표와 평가 질문

BCE: 정답에 부여한 확률의 손실

AUROC: 두 클래스의 점수 순서

0.5 분류: 기준선 어느 쪽인가

같은 support 증가에도 CDLD와 MF는 다르게 변했다

자료	방법	AUROC 변화	정확도 (%p)	민감도 (%p)	특이도 (%p)
MIMIC	CDLD	-0.0030	+6.21	+2.19	-4.69
MIMIC	MF	+0.0528	+12.43	-6.00	+52.86
eICU	CDLD	-0.0093	+6.11	+2.21	-10.43
eICU	MF	+0.0310	+5.01	-7.70	+46.09

CDLD: 감수성 검출 ↑ / 비감수성 검출 ↓

MF: 감수성 검출 ↓ / 비감수성 검출 ↑

support 0 → 50 변화. AUROC는 원래 척도, 나머지 지표는 퍼센트포인트 차이

이 결과를 실제 사용으로 연결하려면 무엇을 확인해야 할까?

관측 환경

기존약 4개를 허용한 후향적
평가

실제 검사 순서·보고 시점에서
같은 입력을 얻을 수 있는지
확인

외부 표본

eICU 155명 · 218 사례

AUROC 가능 26조합 중 5개는
비감수성 사례가 1개

결과의 정밀도

조합 동일가중 점추정 비교

환자 단위 신뢰구간 미산출
개발 중 평가 결과 반복 검토

CDLD의 신규약 적응: 가능성과 지표별 효과를 함께 확인했다

- 01 새 목표약에 소수 관측으로 적응하고 외부 자료에 적용했다
- 02 전체 방법의 상대 성능은 자료·관측 수·지표에 따라 달랐다
- 03 CDLD 적응은 정확도·F1·확률 손실을 개선했다

동시에 AUROC·특이도는 감소했다 — 판별력과 두 클래스의 검출을 함께 평가

실험 설정과 자료 출처

최종 평가 설정

28조합 × 3 seed × 10 반복
support: 10 / 20 / 30 / 40 / 50

Finder: 128차원 · 22순환
Predictor: 55epoch
목표약 적응: LR 0.002 · 200/400step

자료와 코드

MIMIC-IV 3.1 / eICU-CRD 2.0
PhysioNet 제한접근 임상 자료

코드 저장소
github.com/dhrim/CDLD_AST